

Looking Beyond the Window: Global-Local Aligned CLIP for Training-free Open-Vocabulary Semantic Segmentation

ByeongCheol Lee, Hyun Seok Seong, Sangeek Hyun, Gilhan Park, WonJun Moon, Jae-Pil Heo

要点 (ref: 1)

CLIP ベースの training-free¹ Open-Vocabulary Semantic Segmentation (OVSS) では、高解像度画像を扱うため overlapping sliding-window² 推論が不可欠

しかし、window の独立処理により大域的な文脈が失われ、同一物体に対するラベルの不一致や境界における grid artifact³ が発生する 本論文は、この精度の低下が「学習不足」ではなく「推論時の receptive field の不足」に起因すると指摘している

これらに対処するため GLA-CLIP では以下を導入する

- ・ global key/value: 参照先を画像全体の window に拡張
- ・ proxy anchor: local query に内在する window bias を軽減

¹すでに訓練済みのモデル (e.g. CLIP や LLM) のパラメータは凍結し、プロンプトやコンテキスト、外部のルール (e.g. 検索・ルールベースの処理) を工夫して性能を上げるアプローチ

²画像を重ねりを持たせて切り出す。window は 1 枚のサブ画像

³Figure 1 参照

- ・ dynamic normalization: object scale に応じて global attention を適応的に調整

GLA-CLIP は既存の training-free OVSS に対し、再学習なしで window 間の推論の整合性を向上させる拡張手法



Window 境界の不整合 (ref: 3.1.2)

CLIP は低解像度画像で事前学習されているため、大域的な画像空間は十分獲得しているが、高解像度での dense prediction¹ には不向きである。そのため、既存の training-free OVSS は overlapping crop ごとに独立して推論を行い、後から結果を統合する。

- ・ 画像全体を俯瞰できないため、同一物体でも window ごとに異なるラベルが付与されやすい
- ・ 特に大きな物体 (large object) や背景 (stuff category) において文脈分断の影響が顕著
- ・ 本論文では、この推論の不整合を Boundary Error Rate (BER) という指標で定量化

重なり領域の単純な平均化では解決できない、window 境界における根本的な意味のズレが課題

¹ピクセル単位でのタスク (e.g. セグメンテーション)



(a) Boundary error rate comparison across datasets

(b) Grid artifacts from contextual discrepancy across windows

Figure 1. Comparison of segmentation consistency near window boundaries. (a) We evaluate segmentation inconsistency using the Boundary Error Rate (BER). BER is defined as the proportion of pixels near adjacent window boundaries where predicted labels differ despite identical ground-truth. ProxyCLIP yields high BER due to its lack of cross-window interaction, whereas BER is significantly reduced in ours by incorporating global context into attention process. More details in Appendix A. (b) ProxyCLIP exhibits grid artifacts (marked with white circles), caused by the limited receptive field within individual windows. In contrast, ours mitigates these artifacts by leveraging contextual information beyond local windows.

Figure 1: BER の低下と grid artifact の抑制により、window 境界の不整合が主要課題だと示している。

既存法のギャップ (ref: 2.2)

既存法でも sliding-window は用いられるが、window 間での意味的な情報の共有が不十分である。処理 token を増やしても、query 自体が局所的な window の特徴から生成される限り、attention は window 内部に偏ってしまう。

- ・ 局所的な精度は高くても、大きな物体や背景において大域的な文脈が途切れやすい
- ・ overlapping merge¹ は境界の logit を平滑化するのみで、根本的な意味のズレは補正できない
 - 結局その window ごとのセグメンテーション結果は変化していない
- ・ 結果として、BER の悪化、小物体の推論の不安定化、grid artifact の残存といった問題が生じる

根本的な原因は text-image alignment の不足ではなく、(attention の) query が局所的な情報のみで構成されている点にある

¹複数の window に含まれる画素に対する結果の統合処理

GLA-CLIP の全体像 (ref: 3)

GLA-CLIP は新しい backbone¹ を学習するのではなく、既存の training-free OVSS に対する推論時の補正モジュールとして機能する。

1. Key-Value Extension: query は局所的なまま、参照先の key/value を全 window へ拡張
 2. Proxy Anchor: local query を画像全体で安定した代表点へ置換し、window bias を軽減
 3. Dynamic Normalization: object scale に応じて attention の閾値とスケールを動的に調整
- 単なる global context の追加に留まらず、推論時の bias とスケールのミスマッチを同時に補正するアーキテクチャ

¹モデルの基盤となる特徴抽出器 (e.g. CLIP, DINO)




Figure 2. Overview of our proposed framework. The input image is first divided into overlapping windows and processed using frozen backbones: a Vision Foundation Model (VFM, e.g., DINO) and CLIP. We introduce a Key-Value Token Extension, where VFM features from the current window F_{vfm} serve as *query* tokens, while *key* tokens are gathered from all windows to provide global context. The corresponding *value* tokens V are extracted from the final transformer layer of CLIP. Cross-attention is then applied, followed by a projection layer to generate the final visual features F_{visual} . To stabilize attention across windows, each query token is replaced with a semantically representative proxy anchor. Finally, a dynamic normalization scheme adjusts attention strength based on object size, approximated by the number of positive samples associated with each proxy anchor.

Figure 2: Overview: local query に対して global key/value を参照し、proxy anchor と dynamic normalization で attention を安定化する

Key-Value Extension (ref: 3.2)

local window から生成した query は維持しつつ、key と value には全 window から集めた情報を適用する(query 自体は local しか考慮しないが、返答としては全体を知ったものを用意しておく) これにより、現在の window の query が画像全体の token を参照可能となり、receptive field のみが拡張される。

- ・ 大きな物体や背景を、複数 window にまたがって大域的に捉えることが可能
- ・ baseline モデルを再学習することなく、scene-level の手掛かりを導入できる
- ・ ただし、query 自体は局所的であるため、この段階ではまだ inner-window への偏りが残存する

Key-Value Extention. 数式

$$A_{\text{ext}} = QK_{\text{global}}^T \quad (1)$$

$$F_{\text{visual}} = \text{Proj}(A_{\text{ext}} V_{\text{global}}) \quad (2)$$

- Q は現在 window の query、 K_{global} と V_{global} は全 window から集めた token。
- 参照先だけを拡張するので既存 pipeline に差し込みやすい
- V_{global} : 全 window から集めた value(情報本体)。各パッチの視覚特徴が入っている
- A_{ext} : query, (global) key の類似度から作成した attention。どのパッチをどれくらい使うか
- $\text{proj}(\cdot)$: attention を使って、value を重み付きで集約し 1 つの特徴にまとめた後、線形変換をして特徴の次元や表現を整える

Proxy Anchor (ref: 3.3)

global key/value を参照可能にしても、query が局所特徴量に由来する限り、現在の window 内の類似 token を過大評価しがちである。本論文ではこれを「window bias」と定義し、query を意味的に安定した代表点 (Proxy Anchor) へと置換する。

- ・ 各 query に対し、全 window から cosine 類似度の高い token 群を抽出
- ・ それらの平均を反復的に計算し、新たな proxy anchor を生成
- ・ proxy anchor を基に attention を再計算し、空間的近さよりも意味的な類似度を重視させる

Proxy Anchor 数式

より意味的に安定した Proxy Anchor の作成（以降 query として使う）

$$P_i^0 = \{j \mid Q_i^0 K_j^T > \rho\} \quad (3)$$

$$Q_i^t = \frac{1}{|P_i^{t-1}|} \sum_{j \in P_i^{t-1}} K_j \quad (4)$$

式(3)は i 番目の query に対して似ている token のインデックスの集合

- ・ Q_i^0 : i 番目の query(初期状態)
- ・ K_j : j 番目の key(他のパッチの特徴)
- ・ ρ : 閾値

式 4 は式 3 で集めた類似 token の平均をとる

- ・ P_i^{t-1} : 前ステップで集めた類似トークンのインデックスの集合
- ・ $|P_i^{t-1}|$: その数（集合の大きさ）

- ・ ΣK_j : 特徴の和

Dynamic Normalization (ref: 3.4)

global token の増加は大きな物体の認識には有利だが、小物体では positive token が少なくノイズに埋没しやすくなる。これを防ぐため、query ごとに attention の閾値とスケールを動的に変化させ、global context の影響度を調整する。

- u : window 数 L に応じて閾値を引き上げ、global token 増加に伴うノイズを抑制
- w_i : scaling value として定義。高信頼度 token 数 $|P_i|$ が少ないほど大きな値を取り、小物体の特徴を保護
- データセット固有の手動チューニングを排除し、object scale に応じた適応的に処理

$$\text{Attn}_i = w_i \left(\mathbf{S}_{\text{proxy}} - \frac{u}{NL} \sum_{j=1, \dots, NL} [\mathbf{S}_{\text{proxy}}]_{ij} \right) \quad (5)$$

$$u = 1 + \lambda_1 \log(1 + L) \quad (6)$$

$$w_i = 1 + \frac{\lambda_2}{|P_i|} \quad (7)$$

global context の過剰な導入による小物体の認識精度低下を、query 単位で効果的に防ぐ手法




Figure 3. Visualization of attention maps for an anchor *query* token. Proxy-based attention enhances focus on semantically relevant regions across both inner- and outer-window areas. The subsequent dynamic normalization further suppresses irrelevant responses, especially from noisy tokens, yielding sharper and more semantically consistent attention distributions.

Figure 3: Key-Value Extension だけでは attention が散り、proxy anchor と dynamic normalization を入れると意味的に一貫した領域へ集中する。

主結果 (ref: 4.2)

8つの Semantic Segmentation ベンチマークにて、mean Intersection-over-Union (mIoU)¹ を用いて評価を実施。メインの実験設定として、重みを固定した CLIP ViT-B/16 および DINO ViT-B/8 を使用している。

- CLIP-DINOiser ベース: 平均 **+1.6** mIoU の改善
- ClearCLIP への統合: **+1.2** mIoU の改善
- ProxyCLIP への統合: **+0.6** mIoU の改善
- SCLIP への統合: **+1.6** mIoU の改善
- 手動チューニングなしで平均 **44.0**、データセット特化チューニングありで **44.3** を達成

el	Train	External Model	*DS Hyperparameter	With Background				Without Background				A
				V21	PC60	C-Obj	V20	PC59	C-Stf	City	ADE	
P-DINOiser Setting												
ipViT [46]	✓	-	✗	50.4	18.7	27.5	79.7	23.4	15.3	11.1	9.2	2
o [40]	✓	-	✗	25.1	19.9	15.7	57.7	22.3	14.8	21.6	11.2	2
P-DIY [44]	✗	-	✗	59.9	19.7	31.0	79.7	19.8	13.3	11.6	9.9	3
[7]	✓	-	✗	55.0	30.4	31.6	83.2	33.9	22.4	24.0	17.1	3
P-DINOiser [45]	✓	DINO	✗	62.2	32.4	35.0	80.2	35.9	24.6	31.7	20.0	4
tyCLIP + GLA [‡]	✗	DINO	✗	63.4	35.8	37.3	80.4	39.4	26.3	33.5	19.1	4
irCLIP Setting												
irCLIP [23]	✗	-	✗	51.8	32.6	33.0	80.9	35.9	23.9	30.0	16.7	3
irCLIP + GLA	✗	-	✗	55.6	33.2	34.6	79.7	36.5	24.6	32.7	17.4	3
tyCLIP Setting												
448 Image Resize, 336 Crop size, 112 Stride, With rename trick on Background Classes												
tyCLIP [24]	✗	DINO	✗	61.3	35.3	37.5	80.3	39.1	26.5	38.1	20.2	4
tyCLIP + GLA	✗	DINO	✗	63.2	35.8	37.7	81.5	39.7	26.8	38.5	20.3	4
IP Setting												
336 Image Resize, 224 Crop size, 112 Stride, With rename trick												
IP [42]	✗	-	✗	59.1	30.4	30.5	80.4	34.2	22.4	32.2	16.1	3
IP + GLA	✗	-	✗	59.8	32.0	32.8	80.5	35.1	24.2	35.1	18.0	3
G [20]	✗	-	✗	62.1	31.6	34.2	82.5	34.7	23.2	26.2	15.8	3
CLIP [18]	✗	-	✗	58.9	32.2	33.2	79.7	35.2	23.3	35.5	17.4	3
CLIP [50]	✗	-	✓	61.1	33.5	35.0	86.0	36.8	24.7	35.9	18.0	4
CP [8]	✗	-	✓	65.8	35.3	37.2	84.3	38.0	24.9	33.3	18.4	4
-CLIP [16]	✗	-	✗	64.2	36.0	37.4	84.9	39.7	24.5	40.2	19.6	4
SS [2]	✗	-	✗	-	-	-	80.2	35.9	23.6	37.0	18.4	
IS [22]	✗	DINO	✓	65.8	36.7	37.8	87.8	40.2	26.7	39.4	20.4	4
tyCLIP + GLA (Best [§])	✗	DINO	✓	66.7	36.3	37.7	84.7	40.2	27.2	41.2	20.5	4
tyCLIP + GLA	✗	DINO	✗	66.3	36.1	37.7	84.2	39.9	26.9	40.8	20.0	4

1. Open-vocabulary semantic segmentation results on 8 datasets using CLIP ViT-B/16. *DS Hyperparameter: dataset-specific parameters (not used in Ours). †Rename trick: multiple textual prompts per class. ‡GLA: Adaptation for ClearCLIP [23], SCLIP [24]. § Best: optionally uses dataset-specific hyperparameters (u, w), by manual tuning.

Figure 4: Table 1: GLA adaptation は ClearCLIP, ProxyCLIP, SCLIP など複数の既存法に一貫して追加利得を与える。

¹semantic segmentation の代表的な評価指標。特定クラスについて予測と正解の交集を計算しその平均を取る

手動チューニングなしで複数の既存手法に安定した精度向上をもたらす、高い汎用性と実用性が特長

質的比較 (ref: 4.2)

Figure 5 において、Pascal VOC, COCO-Stuff, Cityscapes いずれのデータセットでも、window を跨ぐ同一領域に対して一貫したラベル付与が確認できる。

- ・ ProxyCLIP や CASS と比較して境界が自然であり、window 間の不自然な段差が顕著に低減
- ・ 特に stuff category (背景) や大きな物体において、視覚的な改善が明確
- ・ 定量的な BER の改善が、定性的な視覚的一貫性の向上として現れている




Figure 4. Qualitative results among ProxyCLIP [24], CASS [22], Ours on Pascal VOC21 [17], COCOstuff [4], and Cityscapes [12].

Figure 5: Pascal VOC, COCO-Stuff, Cityscapes で、ProxyCLIP や CASS より window 境界の不整合が少ない。

単なる mIoU のスコア向上に留まらず、推論結果における window artifact を視覚的にも大きく削減

Ablation (ref: 5.1)

Baseline モデル (30.8) に対し、Key-Value Extension と Dynamic Normalization の追加で **43.1**、Full model で **44.0** へと向上。精度改善の最大の要因は global context の導入だが、残り 2 つのモジュールが推論の不安定性を効果的に補っている。

- ・ Key-Value Extension の寄与が最も大きく、従来法の課題が context 欠落にあることを裏付け

	KVE	Proxy	Norm			mIoU
			Fixed	Best	Dyna	
(a)						30.8
(b)	✓				✓	43.1
(c)		✓			✓	43.0
(d)	✓	✓	✓	✓		44.3
(e)	✓	✓		✓	✓	44.0

Table 2. Ablation study of each component in our method. KVE: Key-Value Extension, Proxy: Proxy Anchor-based Attention, Norm: Normalization (Best, Dynamic). Dataset-specific tuning is applied for ‘Best’ normalization configuration, with detailed results in Tab. 1.

Figure 6: Table 2: full model が最良で、proxy anchor と dynamic normalization の両方に追加利得がある。

- ・ Proxy anchor による inner-window bias の補正がさらなる精度向上に寄与
- ・ Dynamic normalization はデータセット固有のパラメータチューニングを不要にする役割を果たす
- ・ backbone を変更しても改善効果が維持されるため、attention 設計そのものの有効性が示された

提案する 3 つの要素は独立して機能し、それぞれ Context 拡張、Bias 補正、Scale 補正の役割を担う

限界と要点 (ref: 6)

GLA-CLIP は CLIP-based モデルで問題視される局所性に対してのひとつのアプローチ

その有効性は、単に global context を導入した点にあるのではなく、推論段階において local query 固有の bias や object scale の差異までも同時に補正した点

- ・ 強み: 既存の training-free OVSS への容易な後付けが可能であり、8 つのベンチマークで一貫した改善を達成
- ・ 弱み: 全 window の token を参照するため、計算量およびメモリコストが増大する
- ・ 今後の課題: 推論負荷を抑えつつ、高品質な token をいかに効率的に選別するか