


後藤 個別ゼミ OV-Seg

2026-04-12

問題設定：Open-Vocabulary Segmentation



Close-Vocabulary Segmentation は、事前に決められたクラス（例：車・人・木）だけをラベルづけする

Open-Vocabulary

- ・ 画像中の領域を「テキストによる自由な説明（例：『赤いオープンカー』『大型の白い雲』）」にマッチさせたい
- ・ そのテキストクラスは訓練時には見ていなくてもいい

Figure 1: The segmentation results comparison of the closevocabulary and open-vocabulary segmentation.¹

¹https://www.researchgate.net/figure/The-segmentation-results-comparison-of-the-closevocabulary-and-open-vocabulary_fig5_390405782

OV-Seg

主流アプローチのボトルネック

1. マスク生成（クラス非依存）
2. マスク領域のテキスト分類
 - ・ 事前学習済みの VLM（例：CLIP）で、マスクされた領域画像を入力し、テキストラベルを割り当てる。

→ CLIP は”自然な全体画像”が前提なので背景が抜け落ちたマスク付き画像を上手く扱えない




Figure 1. (a) CLIP is pre-trained with natural images with little data augmentation. (b) Two-stage open-vocabulary semantic segmentation approaches first generate class-agnostic mask proposals and then leverage pre-trained CLIP to do open-vocabulary classification. The input of the CLIP model is cropped masked images, which have huge domain gap from the natural images. (c) Our analysis reveals that pre-trained CLIP does not work well on masked images.

提案手法 1 : Mask-adapted CLIP

- CLIP を **マスク付き画像に強いモデル** に変える
- 既存のキャプションデータセットを用い、CLIP を使ってマスク領域の画像とキャプション中の名詞をマッチングさせたペアを作成し擬似訓練データを自動作成
 - マスク情報が載ったデータを作成できる
- それらを使って CLIP を fine-tuning
- ノイズは多いが語彙が非常に多様なデータを用いることができる




Figure 3. For the given image-caption pair, only "apple" and "orange" are categories in COCO. By extracting nouns from captions, we can also get a novel "teapot" category.

提案手法 2 : Mask prompt tuning

- ・ マスク画像は背景がなく、切り取られた領域だけであるため、**どのピクセルが背景か**を教えてやると CLIP がうまく動作しやすくなる
- ・ CLIP の重みを一切変更せずにプロンプト側のテンプレートを調整する




Figure 4. The proposed mask prompt tuning can adapt CLIP to masked images without changing its weights. We replace the zero tokens from masked patches with learnable mask prompts.

追試：実験設定

共通設定：Train = COCO-Stuff-171 Test = ADE20K-150 (val) Batch = 32 Max iter = 120,000 WarmupPolyLR
(warmup 1,500 iter) Grad clip = 0.01

項目	Config A	Config B
Backbone	Swin-B (22K, 384×384)	ResNet-101 DeepLab
CLIP	ViT-L/14	ViT-B/16
Embedding dim	768	512
Crop size	640×640	512×512
Base LR	6e-5	2e-4
Backbone LR mult	1.0	0.1
Weight decay	0.01	1e-4
Mask THR	0.4	0.5

結果 (ADE20K-150 val) (事前学習済みパラメータ)

Config	mIoU	fwIoU
Config A (Swin-B / ViT-L/14)	29.58	57.33
Config B (R-101 / ViT-B/16)	24.87	52.98

Config A : IoU 上位

クラス	IoU
sky	86.82
toilet	84.61
pool table	77.21
person	76.10
road	75.05


Config A : IoU 下位

クラス	IoU
field	0.00
pillow	0.00
kitchen island	0.00
base / pedestal	0.00
buffet	0.00

追試：モデルの学習

OVSeg セグメンテーションモデルの学習

- ・ open-vocab 分類を CLIP 特徴で行う
- ・ mask 単位で crop した領域を CLIP に通す



学習途中