

LLaDA2.1: Speeding Up Text Diffusion via Token Editing

Tiwei Bie et al.

問題設定

- ・ LLM 推論の主流は **Autoregressive (AR)** デコーディング：1 トークンずつ逐次生成
- ・ **Discrete Diffusion LM (dLLM)** はマスクを並列に予測することで高速化を目指す
- ・ しかし dLLM は **速度と品質のトレードオフ** を抱えている
 - ステップ数を増やすと品質は AR 並みだが速度優位が消える
 - ステップを減らすと品質が劣化する

このトレードオフを根本から解消できるか？

モチベーション

LLaDA2.0 で採用された M2T デコーディングの 3 つの問題

1. **Exposure Bias** : 訓練はきれいなマスク列に対して行われるが、推論では部分的に予測済みのノイジーな列を受け取る → エラーが蓄積する
 2. **Stuttering (n-gram 反復)** : 位置ごとに独立にサンプリングするため、同じトークンが繰り返されやすい
 3. **修正不可能** : 一度配置したトークンは後から訂正できない
- 既存手法 (ReMDM, Prophet など) は訓練なしのパッチ適用にとどまり根本解決になっていない

先行研究

共通の課題：一度置いたトークンを書き換える学習の目的関数が存在しない

手法	概要	課題
LLaDA (2025.02)	dLLM 8B、AR と同等品質	ステップ数 ≈ 応答長が必要
LLaDA2.0 (2025.12)	100B MoE に拡張	M2T のまま、速度問題は未解決
ReMDM / Prophet	低信頼度トークンの再マスク	訓練なしパッチ、100B 未検証

新規性

確定済みトークンを推論中に書き直す **Token Editing** のための目的関数を導入

1. **Draft-and-Edit パラダイム** : M2T と T2T を同ステップで実行
2. **Mixture of M2T and T2T** : editing を学習させる新しい目的関数と Multi-turn Forward (MTF) データ拡張
3. **ELBO-based Block-level Policy Optimization (EBPO)** : dLLM の 100B スケールで初めて成功した RL フレームワーク

アイデア：Token Editing

- ・ 従来の M2T デコーディング：[MASK] → トークン（一方向・不可逆）
- ・ LLaDA2.1 のデコーディング：各ステップで **2 種類の更新集合** を動的に決定
 - **Unmasking Set** Γ_t ：信頼度 τ_{mask} を超えた [MASK] 位置を確定
 - **Editing Set** Δ_t ：すでに確定済みだが、モデルの予測が現トークンと異なり、かつ信頼度 τ_{edit} を超えた位置を上書き

$$\text{更新位置} = \Gamma_t \cup \Delta_t$$




Figure 1: **Aggressive parallel drafting**, backed by retroactive correction, accelerates inference.

提案手法：訓練

二つのストリームを組み合わせた目的関数

- ・ **M2T ストリーム**：従来通り、マスクから正しいトークンを生成（ドラフト作成能力）
- ・ **T2T ストリーム**：入力から正しいトークンを復元（自己訂正能力）

Multi-turn Forward (MTF) データ拡張

- ・ 訓練中に「中間編集状態」のシーケンスを生成し、多様な (ドラフト, 修正目標) ペアを学習
- ・ 実際の推論過程に近い状況に対処できるようにする

→ アーキテクチャの変更は不要。訓練目的の変更だけで実現




Figure 2: Overview of training & inference framework of LLaDA2.1

提案手法：推論モードと RL

- ・ **S Mode (Speedy)** : τ_{mask} 低め (積極的展開) → 高スループット、T2T 訂正に依存。コード生成・数学向き
- ・ **Q Mode (Quality)** : τ_{mask} 高め (慎重展開) → 高品質、スループットは中程度。汎用・instruction following 向き

Multiple Block Editing (MBE) : 後続ブロックを参照して前のブロックを遡及修正 → 整合性向上

ELBO-based Block-level Policy Optimization (EBPO)

- ・ dLLM の系列対数尤度は計算困難 → ELBO 近似 + Block-Causal Masking で勾配推定を計算可能に
- ・ 100B 規模で RL を初めて成功させた

実験設定

- ・ **モデル** : LLaDA2.1-Mini (16B MoE) と LLaDA2.1-Flash (100B MoE)
- ・ **ベンチマーク** : 33 タスク
 - 推論 : GPQA, DROP, MATH
 - コード : HumanEval+, BigCodeBench, LiveCodeBench
 - 知識・常識 : TriviaQA, PIQA, HellaSwag, C-Eval
- ・ **比較対象** : LLaDA2.0-Mini/Flash (直接の前身)、Ling、Qwen3 (AR モデル)
- ・ **主要メトリクス**
 - **TPS** (Tokens Per Second) : 実時間スループット
 - **TPF** (Tokens Per Forward pass) : 1 回の forward あたりの生成トークン数 (AR では 1)

実験結果：Flash

モデル	平均スコア	TPF
LLaDA2.0-Flash	72.43	3.08
LLaDA2.1-Flash Q Mode	73.54	3.64
LLaDA2.1-Flash S Mode	72.34	5.93

Q Mode は品質・速度の両面で LLaDA2.0-Flash を上回る

Table 1: Benchmark Performance of LLaDA2.1-flash, comparing with several baseline models. For diffusion language model, we report its scores across each benchmark along with its TPF (tokens per forward); for AR model, we report its scores only, as its TPF is inherently equal to 1.

Benchmark	Qwen3-30B-A3B-Inst-2507 (Score)	Ling-flash-2.0 (Score)	LLaDA2.0-flash (Score TPF)		LLaDA2.1-flash (S Mode) (Score TPF)		LLaDA2.1-flash (Q Mode) (Score TPF)	
Average	73.09	71.52	72.43	3.08	72.34	5.93	73.54	3.64
Knowledge								
GPQA	54.14	69.16	62.31	3.29	66.67	3.95	67.30	2.37
MMLU-Pro	74.21	77.55	74.79	2.36	75.31	4.43	76.59	2.62
C-EVAL	88.12	87.54	85.21	1.90	86.93	2.71	86.71	1.75
PHYBench	29.84	27.67	30.06	2.70	26.04	4.10	28.23	2.66
TriviaQA	65.61	69.76	66.88	1.94	72.55	4.30	72.93	2.92
Reasoning								
BIG-Bench Hard	85.54	89.36	86.75	2.66	87.82	5.61	88.69	3.28
BIG-Bench Extra Hard	37.80	23.24	27.86	4.60	33.51	5.04	35.77	3.17
bbh-zh	86.18	75.09	87.52	3.21	82.55	5.78	86.23	3.77
MuSR	79.15	82.72	80.48	1.70	80.10	2.90	79.84	1.85
ZebraLogic	90.97	87.60	82.30	2.74	84.20	5.80	88.90	3.26
PrOntoQA	97.12	97.88	96.50	2.64	95.00	9.23	97.00	5.73
PIQA	91.57	91.95	92.76	1.43	92.44	2.38	92.17	1.44
OCNLI	71.59	65.36	71.63	1.09	72.17	1.83	72.75	1.32
HellaSwag	86.31	81.59	84.97	1.26	85.60	2.31	85.31	1.51
KOR-Bench	69.20	69.44	63.04	3.44	62.80	4.97	65.12	2.77
DROP	87.57	88.32	87.90	2.26	87.55	5.40	87.86	2.53
SQuAD 2.0	89.51	81.32	90.00	3.10	90.65	5.01	90.80	3.90
Coding								
LiveCodeBench	46.42	52.48	42.51	4.23	44.05	6.48	45.37	3.80
CRUXEval-O	86.75	82.75	85.12	3.21	85.25	6.54	87.50	3.80
MBPP+	78.21	80.89	79.37	4.02	76.72	10.43	77.25	5.96
HumanEval+	87.88	87.58	88.41	6.45	89.63	13.81	89.63	9.18
MultiPL-E	70.67	65.76	74.87	3.14	70.89	7.77	73.34	4.33
BigCodeBench-Full	41.49	40.70	41.58	3.33	37.11	8.51	39.21	4.70
BIRD-SQL	47.75	47.49	45.76	2.16	42.18	5.09	44.04	2.95
Spider	81.79	80.58	82.49	4.42	79.18	8.74	81.04	5.70
Math								
AIME 2025	61.88	55.89	60.00	4.57	63.33	5.36	63.33	3.46
OlympiadBench	77.59	76.19	74.07	3.70	75.85	6.46	76.59	3.81
CSM-Plus	89.41	89.71	89.74	2.68	89.23	7.14	89.69	3.83
CMATH	96.58	96.52	96.90	2.17	96.54	4.84	96.63	2.65
Omni-MATH	54.00	53.00	50.30	3.39	52.30	6.01	54.10	3.50
Agent & Alignment								
IFEval-strict-prompt	83.73	81.15	82.62	1.47	83.36	2.24	83.55	1.41
BFCL v3	73.41	67.69	74.94	4.87	74.86	9.24	75.61	6.76
Nexus FC	49.93	36.25	50.45	5.53	44.83	11.29	47.65	7.38

実験結果：Mini

モデル	平均スコア	TPF
LLaDA2.0-Mini	63.39	2.60
LLaDA2.1-Mini Q Mode	63.90	3.12
LLaDA2.1-Mini S Mode	62.07	5.34



Mini 系列でも Q Mode は LLaDA2.0-Mini より高品質・高 TPF

Table 2: Benchmark Performance of LLaDA2.0-mini, comparing with several baseline models. For diffusion language model, we report its scores across each benchmark along with its TPF (tokens per forward); for AR model, we report its scores only, as its TPF is inherently equal to 1.

Benchmark	Qwen3-8B (no.think) (Score)	Ling-mini-2.0 (Score)	LLaDA2.0-mini (Score TPF)		LLaDA2.1-mini (S Mode) (Score TPF)		LLaDA2.1-mini (Q Mode) (Score TPF)	
Average	61.59	64.72	63.39	2.60	62.07	5.34	63.90	3.12
Knowledge								
GPQA	48.01	59.41	47.76	2.73	48.36	3.62	53.28	2.12
MMLU-Pro	65.83	67.18	64.27	2.15	63.42	4.22	64.84	2.41
C-EVAL	80.60	82.17	81.80	1.78	78.40	3.39	78.59	1.91
PHYBench	9.76	14.59	11.70	2.48	12.75	4.41	13.05	2.52
TriviaQA	52.51	55.63	51.33	1.54	53.33	3.21	54.24	2.02
Reasoning								
BIG-Bench Hard	79.48	83.70	78.21	2.36	78.42	5.02	80.58	2.86
BIG-Bench Extra Hard	18.27	14.81	16.47	2.03	15.30	3.19	15.78	1.66
bbh-zh	80.09	66.11	75.75	2.77	67.65	3.89	70.40	2.35
MuSR	70.02	71.36	71.48	1.45	70.43	2.48	71.89	1.56
ZebraLogic	37.48	79.85	64.20	2.30	68.50	5.38	77.10	2.93
PrOntoQA	93.12	96.06	86.00	2.36	87.50	4.86	84.50	2.73
PIQA	88.30	87.54	86.51	1.45	84.87	2.59	86.89	1.45
OCNLI	61.49	60.17	64.51	4.06	61.02	1.78	61.59	1.23
HellaSwag	79.56	69.02	79.01	1.50	75.71	2.39	76.19	1.49
KOR-Bench	54.96	63.20	49.92	2.45	46.64	4.28	48.00	2.35
DROP	84.56	78.80	81.91	2.02	81.55	5.84	82.37	2.87
SQuAD 2.0	85.21	75.56	86.50	2.47	84.51	4.33	85.13	3.09
Coding								
LiveCodeBench	26.76	42.29	31.83	3.34	28.85	6.42	30.40	3.63
CRUXEval-O	74.06	76.12	71.62	2.78	70.62	5.85	73.75	3.35
MBPP+	72.69	77.25	78.24	3.43	73.28	10.59	74.07	6.30
HumanEval+	79.50	80.03	81.40	5.16	80.49	12.32	82.93	7.77
MultiPL-E	61.70	67.09	67.46	2.78	64.16	7.23	67.17	4.01
BigCodeBench-Full	36.05	35.00	32.89	2.87	30.18	7.33	34.39	4.09
BIRD-SQL	36.11	39.67	39.34	1.96	37.32	4.48	38.40	2.42
Spider	72.80	76.43	76.76	3.93	75.78	7.98	77.55	5.48
Math								
AIME 2025	22.08	47.66	36.67	2.41	36.67	6.34	43.33	3.29
OlympiadBench	55.33	72.30	67.70	2.63	64.30	7.08	66.67	3.99
GSM-Plus	85.56	87.18	86.50	2.41	85.88	6.82	86.55	3.69
CMATH	95.42	96.40	95.72	1.98	95.63	4.94	94.99	2.56
Omni-MATH	33.20	48.80	41.70	2.57	41.70	6.41	43.60	3.56
Agent & Alignment								
IFEval-strict-prompt	84.29	76.16	80.78	1.24	81.33	1.83	83.18	1.25
BFCL v3	70.12	53.75	70.72	4.26	72.06	7.39	73.61	5.14
Nexus FC	37.71	34.38	35.18	4.06	31.59	8.27	33.69	4.91

実験結果：スループット

LLaDA2.1-Flash (100B, S Mode + 量子化) の TPS



アブレーション

1. **MBE の効果**：推論・コードタスクでスコアが一貫して向上。スループットは微減
2. **MTF データ拡張の効果**：除去すると S Mode の品質が顕著に低下 → 多様な編集シナリオの学習が必要
3. **T2T ストリームの効果**：除去すると S Mode で大幅な品質劣化 → 自己訂正能力の学習が不可欠
4. **量子化の影響**：スループット向上、コード・数学は許容範囲内。open-ended タスクは影響大
5. **EBPO の効果**：RL 無しでは推論・instruction following スコアが低下

Table 4: Performance comparison of LLaDA2.1-flash and Mini variants with and without Multi-Block Editing (MBE) across benchmarks. Each cell reports *Score* | *TPF*.

Category	Benchmark	LLaDA2.1-flash				LLaDA2.1-mini			
		w/o MBE		w/ MBE		w/o MBE		w/ MBE	
		Score	TPF	Score	TPF	Score	TPF	Score	TPF
Knowledge	MMLU-Pro	75.31	4.43	75.90	3.88	63.42	4.22	63.10	3.66
	TriviaQA	72.55	4.30	72.45	4.28	53.33	3.21	53.41	3.14
Reasoning	bbh-zh	82.55	5.78	83.21	4.85	67.65	3.89	67.94	3.41
	ZebraLogic	84.20	5.80	88.20	5.03	68.50	5.38	70.00	4.62
Coding	LiveCodeBench	44.05	6.48	46.48	5.62	28.85	6.42	29.74	5.44
	CRUXEval-O	85.25	6.54	87.00	5.62	70.62	5.85	70.62	5.02
	BigCodeBench-Full	37.11	8.51	39.30	7.00	30.18	7.33	30.70	6.05
	Spider	79.18	8.74	80.58	8.33	75.78	7.98	76.67	7.59
Math	AIME 2025	63.33	5.36	70.00	4.71	36.67	6.34	36.67	5.25
Agent & Alignment	IFEval-strict-prompt	83.36	2.24	83.55	2.11	81.33	1.83	83.55	1.70
Average	–	70.69	5.82	72.67	5.14	57.63	5.25	58.24	4.59

制限

1. **Stuttering は残る**：T2T 編集で軽減するが、並列サンプリング由来の n-gram 繰り返しを完全には排除できない
2. **KV キャッシュ非対応**：トークンが変化し続けるため、AR モデルのような KV キャッシュ再利用ができない。高 TPF でカバーするが、1 ステップのコストは高いまま
3. **Exposure bias は部分的な解消にとどまる**：T2T 訓練で緩和されるが、完全な解消には至らない
4. **RL と editing の統合**：現在の EBPO は生成全体に対して報酬を与えるが、「訂正操作そのもの」への報酬設計は今後の課題

まとめ

Token Editing（推論中のトークン上書き）を訓練目的に組み込むことで、100B 規模の dLLM において速度と品質のトレードオフを改善した

- ・ 確定済みトークンの書き直しを M2T + T2T を合わせた目的関数で学習
- ・ 高速並列生成 + 自己訂正が可能。KV キャッシュ不可、stuttering 残存
- ・ コード・数学では S Mode が有効。open-ended では Q Mode 推奨
- ・ 再現性のために Γ_t , Δ_t の定義（閾値 τ_{mask} , τ_{edit} ）、MTF 拡張、EBPO 勾配推定の調査が必要